


## פרויקט סופי

### שאלה 1

א.


Final parameters:  $a=0.997333333849981$ ,  $b=2.367999994270291$

2. ו-3.




4.


Error Surface Over Parameters



ג.



Error Surface Over Parameters



מגישים:  
שחר אשר – 209305408  
הדר ליאל הרוש - 211721568

קצב למידה: 0.01

```
# Learning rate  
lr = 0.01 # You might need to adjust the learning rate
```


איטרציות: 1000

```
# Number of iterations  
iterations = 1000
```

הפרמטרים שמצאנו הם:

Final parameters:  $a=0.4946555998532448$ ,  $b=3.0123813348953465$

.T



#### פרמטרים סופיים:

Final parameters:  $a=3.318145436025057$ ,  $b=1.488977981749276$

נראה שהמודל מתאים באופן טוב מאוד לנתונים. הקו האדום (המודל) עובר דרך רוב הנקודות הכחולות (הנתונים). זה מראה שהפונקציה הסינוסואידלית מתאימה היטב למבנה של הנתונים. הפרמטרים הסופיים שהפונקציה `curve_fit` מצאה הם:

- $a = 3.318145436025057$

- $b = 1.488977981749276$



הפרמטר  $a$  הוא הערך שבו הפונקציה הסינוסואידלית מתחילה (הגובה שלה), והפרמטר  $b$  הוא התדירות של הפונקציה. אם נשווה את הערכים האלה לערכים האמיתיים שהשתמשת בהם כדי ליצור את הנתונים, נראה שהפונקציה `curve_fit` מצאה פרמטרים שדי קרובים לערכים האמיתיים. זה מראה שהפונקציה `curve_fit` יכולה להיות כלי יעיל למציאת הפרמטרים של מודל שמתאים לנתונים.


ה. המודל שבחרו הוא:  $f(x) = a \cdot \sin(b \cdot x + c)$ .

a, b ו- c הם הפרמטרים של המודל.


הפרמטרים ההתחלתיים שבחרנו הם:  $a\_val = 1, b\_val = 1, c\_val = 1$


```
# Initial parameters  
a_val, b_val, c_val = 1, 1, 1
```





Error Surface Over Parameters





פרמטרים שנמצאו על ידי Gradient descent:

Final parameters:  $a=0.15534552265847998$ ,  $b=-7.934037154730188$ ,  
 $c=0.0804089890396507$

פרמטרים שנמצאו על ידי curve\_fit:

Parameters found by curve\_fit:  $a=2.0156616351282866$ ,  
 $b=1.0093224363174194$ ,  $c=0.5359304117967073$

הזמן שלוקח ל- Gradient descent:

Time elapsed for gradient descent: 2.051109552383423 seconds

הזמן שלוקח ל- curve\_fit:

Time elapsed for curve\_fit: 0.0010044574737548828 seconds

ההבדלים בין שתי השיטות, Gradient descent (GD) ו-curve\_fit :

- **זמן הריצה:**

- Gradient descent: לקח כ-2.05 שניות למצוא את הפרמטרים האופטימליים.
- curve\_fit: שיטה זו הייתה מהירה באופן משמעותי, ולקחה רק כ-0.001 שניות.

- **הפרמטרים הסופיים:**

- Gradient descent: הפרמטרים הסופיים היו  $a=0.1553$ ,  $b=-7.9340$ ,  $c=0.0804$ .
- curve\_fit: הפרמטרים היו שונים באופן משמעותי עם הערכים  $a=2.0157$ ,  $b=1.0093$ ,  $c=0.5359$ .

- **איכות ההתאמה (כפי שנראית מהגרף):**

- המודל של Gradient descent: הקו האדום אינו מתאים לנקודות הנתונים באופן מדויק; נראה שהמודל מתחת למידה הנדרשת.
- המודל של curve\_fit: הקו הירוק מתאים לנקודות הנתונים באופן מדויק יותר, ומתפס את המגמה הבסיסית באופן יעיל.

ההבדלים נובעים מהתכונות הייחודיות של כל שיטה:

- **Gradient descent:** זהו אלגוריתם אופטימיזציה איטרטיבי שמשמש לעיתים קרובות למציאת המינימום של פונקציה; במקרה זה, ייתכן שהוא לא התכנס לערכים האופטימליים במהלך האיטרציות או שנתקע במינימום מקומי, מה שהוביל להערכות פרמטר שאינן אופטימליות.
- **curve\_fit:** בדרך כלל משתמשת בריבועים פחותים לא ליניאריים להתאמת פונקציה לנתונים, שיכולה להיות יעילה ומדויקת יותר אך יכולה גם להתלוות על הערכות פרמטר ראשוניות.



### שאלה 3

א.

1.  $(p1 \text{ and not } p2) \text{ or } (p1 \text{ and not } p4)$

2.  $(p3 \text{ or } p9) \text{ and } p1$

3.  $(\text{not } p5) \text{ and } p1$

ב. נחשב את מספר הכללים שמסווגים נכונה את סט האימון:  
גודל המטריצה הוא – 3 על 3. ולכן, מספר המטריצות האפשריות הוא:  
 $9^2 = 512$ .

סט האימון שלנו מכיל 6 מטריצות מתוך כל המטריצות (מתוך 512  
מטריצות). לכן, סט המבחן יכיל 506 מטריצות.

יש לנו שתי תשובות אפשריות – TRUE או FALSE. לכן, כל מטריצה  
יכולה להיות מסווגת לאחת מן התשובות – TRUE או FALSE.

↔ מספר הכללים שמסווגים את סט האימון הוא:  $2^{506}$ .